

# §1. ПРЕДВАРИТЕЛЬНЫЙ АНАЛИЗ СТАТИСТИЧЕСКИХ ДАННЫХ

## 1.1. Числовые характеристики (параметры) выборочного распределения

Последовательность  $n$  значений  $x_1, x_2, \dots, x_n$ , полученных в результате наблюдения некоторого процесса, мы будем рассматривать как совокупность значений одинаково распределенных независимых случайных величин  $\xi_1, \xi_2, \dots, \xi_n$ , представляющих собой  $n$  экземпляров одной и той же случайной величины  $\xi$ . Эта последовательность значений называется **выборкой**. В этом случае говорят, что выборка взята из **генеральной совокупности** случайной величины  $\xi$ . Если величина  $\xi$  следует закону распределения  $F(x)$ , то мы будем говорить, что генеральная совокупность распределена по закону  $F(x)$ .

Пусть  $x_1, x_2, \dots, x_n$  – выборка объема  $n$  из некоторой генеральной совокупности. По этой выборке можно оценить основные числовые характеристики генеральной совокупности. Различные элементы выборки  $x_i$  называются **вариантами**. Ряд вариантов, расположенных в порядке возрастания их значений называется **вариационным рядом**. Им пользуются, в основном, при малых  $n$ . Если  $n$  велико, то ряд преобразуют в группировки по отдельным значениям признака  $x$  (дискретная группировка) или по интервалам изменения признака (интервальная группировка), для чего разбивают диапазон изменения признака  $x$ , называемый размахом  $R = x_{\max} - x_{\min}$ , на  $K$  равных интервалов. Для определения количества интервалов рекомендуется правило  $K \approx \sqrt{n}$ , где  $5 \leq K \leq 20$ . Можно пользоваться и другими эмпирическими формулами, например, формулой Стерджеса  $K \approx 1 + 3,322 \lg n$ , но они дают приблизительно одинаковый результат.

Иногда данные для обработки поступают уже в интервальной группировке, или представляется невозможным использовать одинаковые интервалы (например, в экономике).

Результат группировки представляют рядом вариантов или интервалов вариантов, расположенных в порядке их возрастания и рядом соответствующих **частот**. Под **частотой**  $m_i$  признака или интервала понимают число членов выборки с данной вариантой  $x_i$  или, соответственно, число членов выборки, варианты которых лежат в  $i$  – м интервале. **Относительной частотой**  $h_i$

называется отношение частоты  $m_i$  к объему выборки:  $h_i = \frac{m_i}{n}$ . Таким образом,

если проведена группировка, то значению  $x_i$  или  $i$  – му интервалу ( $i = 1, \dots, k$ )

будут отвечать частоты  $m_i$  и относительные частоты  $h_i = \frac{m_i}{n}$ , при этом

$\sum_{i=1}^k m_i = n$ ,  $\sum_{i=1}^k h_i = 1$ , а все выборочные значения, попавшие в  $i$  – ый интервал,

заменяют серединой интервала  $u_i$ .

**Пример 1.** В обувном магазине за день продали 30 пар мужской обуви следующих размеров:

39, 41, 40, 42, 41, 40, 42, 44, 42, 43, 42, 41, 43, 39, 42, 39, 41, 43, 41, 38, 43, 42, 41, 40, 41, 38, 44, 40, 39, 44.

**Решение:** Проведем группировку по отдельным значениям признака, то есть по размеру обуви (дискретная группировка):

|       |       |       |       |       |     |       |     |          |
|-------|-------|-------|-------|-------|-----|-------|-----|----------|
| $x_i$ | 38    | 39    | 40    | 41    | 42  | 43    | 44  | $\Sigma$ |
| $m_i$ | 2     | 4     | 4     | 7     | 6   | 4     | 3   | 30       |
| $h_i$ | 0,067 | 0,133 | 0,133 | 0,233 | 0,2 | 0,133 | 0,1 | 1        |

**Пример 2.** Дана выборка объема  $n = 30$ . Сделать интервальную группировку этой выборки.

20,3; 15,4; 17,2; 19,2; 23,1; 18,1; 21,9; 15,3; 16,8; 13,2; 20,4; 16,5; 19,7; 20,5; 14,3; 20,1; 16,8; 14,7; 20,8; 19,5; 15,4; 19,3; 17,8; 16,2; 15,7; 22,8; 21,9; 12,5; 10,1; 21,1.

**Решение:** Диапазон изменения признака  $x$  (размах выборки)  $R = x_{\max} - x_{\min} = 23,1 - 10,1 = 13$ . Количество интервалов  $K$  можно взять равным 5 ( $K \approx \sqrt{30}$ ), ширина интервала  $d = \frac{R}{K} = \frac{13}{5} = 2,6$ . Таблица интервальной группировки будет выглядеть следующим образом:

| Интервалы                 | 10,1–12,7 | 12,7–15,3 | 15,3–17,9 | 17,9–20,5 | 20,5–23,1 |
|---------------------------|-----------|-----------|-----------|-----------|-----------|
| $m_i$                     | 2         | 4         | 9         | 9         | 6         |
| $h_i$                     | 0,067     | 0,133     | 0,3       | 0,3       | 0,2       |
| середины интервалов $u_i$ | 11,4      | 14,0      | 16,6      | 19,2      | 21,8      |

Варианты, попадающие на границу интервала, отнесены к левому интервалу (можно отнести их и к правому интервалу, а в том случае, если на границу попадает много вариантов, можно их поделить пополам между соседними интервалами).

Иногда статистические данные, полученные для обработки, уже сгруппированы по интервалам. Например, распределение роста 1000 взрослых мужчин имеет вид:

| Рост (см)           | 143-149 | 149-155 | 155-161 | 161-167 | 167-173 | 173-179 | 179-185 | 185-191 |
|---------------------|---------|---------|---------|---------|---------|---------|---------|---------|
| Число мужчин, $m_i$ | 3       | 34      | 185     | 382     | 290     | 92      | 13      | 1       |

В этом случае ширина интервала и количество интервалов заданы.

Итак, пусть  $x_1, x_2, \dots, x_n$  – выборка объема  $n$  из генеральной совокупности, имеющей функцию распределения  $F(x)$ . Числовые характеристики выборки называются **выборочными** (эмпирическими) числовыми характеристиками. Введем основные числовые характеристики:

– *среднее арифметическое (среднее)*

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i; \quad (1.1)$$

Если сделана дискретная группировка, то

$$\bar{x} = \frac{1}{n} \sum_{i=1}^K m_i x_i = \sum_{i=1}^K h_i x_i, \quad (1.2)$$

при интервальной группировке

$$\bar{x} = \frac{1}{n} \sum_{i=1}^K m_i u_i = \sum_{i=1}^K h_i u_i, \quad (1.3)$$

где  $m_i$  – частота,  $K$  – количество интервалов,  $u_i$  – середина  $i$ -го интервала.

– *выборочная (эмпирическая) дисперсия*

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \cdot \left( \sum_{i=1}^n x_i^2 - n(\bar{x})^2 \right). \quad (1.4)$$

При дискретной группировке

$$S^2 = \frac{1}{n-1} \sum_{i=1}^K m_i (x_i - \bar{x})^2 = \frac{1}{n-1} \cdot \left( \sum_{i=1}^K m_i x_i^2 - n(\bar{x})^2 \right), \quad (1.5)$$

при интервальной группировке

$$S^2 = \frac{1}{n-1} \sum_{i=1}^K m_i (u_i - \bar{x})^2 = \frac{1}{n-1} \cdot \left( \sum_{i=1}^K m_i u_i^2 - n(\bar{x})^2 \right). \quad (1.6)$$

**ЗАМЕЧАНИЕ.** Множитель  $\frac{1}{n-1}$  объясняется тем, что  $M[S^2] = \sigma^2$ , т.е.

$S^2$  является несмещенной оценкой  $\sigma^2$ . Если использовать формулу

$$S_1^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2, \text{ то } M[S_1^2] = \frac{n-1}{n} \sigma^2 \neq \sigma^2, \text{ т.е. } S_1^2 \text{ является смещенной}$$

оценкой дисперсии, уменьшающей ее.

– *стандартное (среднее квадратическое) отклонение* является корнем из выборочной дисперсии:

$$S = \sqrt{\frac{1}{n-1} \cdot \sum_{i=1}^n (x_i - \bar{x})^2} = \sqrt{\frac{1}{n-1} \cdot \left( \sum_{i=1}^n x_i^2 - n(\bar{x})^2 \right)}. \quad (1.7)$$

Для сгруппированных данных, соответственно, имеем формулы:

$$S = \sqrt{\frac{1}{n-1} \cdot \left( \sum_{i=1}^K m_i x_i^2 - n(\bar{x})^2 \right)} \quad (1.8)$$

$$S = \sqrt{\frac{1}{n-1} \cdot \left( \sum_{i=1}^K m_i u_i^2 - n(\bar{x})^2 \right)} \quad (1.9)$$

– *коэффициент вариации*

$$V = \frac{S}{\bar{x}}, \quad \bar{x} \neq 0; \quad (1.10)$$

– **выборочные начальные и центральные моменты порядка  $\ell$**   
 ( $\ell = 1, 2, \dots$ ), соответственно, определяются формулами

$$\alpha_{\ell} = \frac{1}{n} \sum_{i=1}^n x_i^{\ell}, \quad \beta_{\ell} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^{\ell} \quad (1.11)$$

Если данные сгруппированы, то получаем следующие формулы:  
 при дискретной группировке

$$\alpha_{\ell} = \frac{1}{n} \sum_{i=1}^K m_i x_i^{\ell}, \quad \beta_{\ell} = \frac{1}{n} \sum_{i=1}^K m_i (x_i - \bar{x})^{\ell} \quad (1.12)$$

при интервальной группировке

$$\alpha_{\ell} = \frac{1}{n} \sum_{i=1}^K m_i u_i^{\ell}, \quad \beta_{\ell} = \frac{1}{n} \sum_{i=1}^K m_i (u_i - \bar{x})^{\ell} \quad (1.13)$$

– **оценка коэффициента асимметрии  $S_k$**  (характеризует симметричность распределения относительно среднего  $\bar{x}$ ) определяется по формуле

$$\hat{S}_k = \frac{\beta_3}{(\beta_2)^{\frac{3}{2}}}. \quad (1.14)$$

– **оценка эксцесса  $E_x$**  (меры островершинности распределения по сравнению с нормальным распределением)

$$\hat{E}_x = \frac{\beta_4}{\beta_2^2} - 3. \quad (1.13)$$

Если  $\hat{E}_x > 0$ , то вершина более острая, а если  $\hat{E}_x < 0$ , то более плоская, чем у нормального распределения. У нормального распределения  $E_x = 0$ .

– **выборочная мода**  $\hat{M}_0$

Для дискретного вариационного ряда (дискретная группировка) мода определяется как значение варианты с наибольшей частотой, если выборка достаточно большая.

При интервальной группировке выбирается интервал, которому соответствует наибольшая частота. Пусть это  $k$ -й интервал  $(t_{k-1} - t_k)$ , его частота равна  $m_k$ , а ширина  $d$ , тогда

$$\hat{M}_0 = t_{k-1} + d \frac{m_k - m_{k-1}}{2m_k - m_{k-1} - m_{k+1}} \quad (1.14)$$

– **выборочная медиана**  $\hat{M}_e$

Определяется, как значение признака, относительно которого выборка делится на две равные по объему части. Если выборка объема  $n$  представлена вариационным рядом, то

$$\hat{M}_e = \begin{cases} x_{k+1}, n = 2k + 1 \\ \frac{x_k + x_{k+1}}{2}, n = 2k. \end{cases} \quad (1.15)$$

При интервальной группировке (интервальный вариационный ряд) сначала находят так называемый медианный интервал  $(t_{s-1} - t_s)$ , номер  $s$  которого определяют из неравенств:

$$\sum_{i < s} m_i \leq \frac{n}{2}, \quad \sum_{i \leq s} m_i > \frac{n}{2},$$

где  $\sum_{i < s} m_i$  – сумма частот всех интервалов левее медианного,  $\sum_{i \leq s} m_i$  – сумма

частот, включающая частоту медианного интервала.

Медиану оценивают с помощью следующей интерполяционной формулы:

$$\hat{M}_e = t_{s-1} + d \left( \frac{\frac{n}{2} - \sum_{i < s} m_i}{m_s} \right), \quad (1.16)$$

где  $m_s$  – частота медианного интервала.

**Пример 3.** Дана выборка объема  $n = 40$  с интервальной группировкой:

| Интервалы | 5–7 | 7–9 | 9–11 | 11–13 | 13–15 | 15–17 | 17–19 |
|-----------|-----|-----|------|-------|-------|-------|-------|
| $m_i$     | 4   | 8   | 11   | 7     | 5     | 3     | 2     |

Найти оценки моды и медианы для этой выборки.

**Решение:**

*Оценка моды.* Ширина интервала равна 2, а наибольшая частота отвечает третьему интервалу (9 – 11) и равна  $m_3 = 11$ , поэтому согласно формуле (1.14)

$$\hat{M}_0 = 9 + 2 \frac{11 - 8}{2 \cdot 11 - 8 - 7} = 9,86.$$

*Оценка медианы.*  $\frac{n}{2} = \frac{40}{2} = 20$ . Определим медианный интервал:

$$m_1 + m_2 = 4 + 8 = 12 < \frac{n}{2} = 20,$$

$$m_1 + m_2 + m_3 = 4 + 8 + 11 = 23 > \frac{n}{2} = 20,$$

следовательно, третий интервал (9–11) – медианный. Поэтому согласно формуле (1.16) получаем оценку медианы

$$\hat{M}_e = 9 + 2 \left( \frac{20 - (4 + 8)}{11} \right) = 10,45.$$

## 1.2. Предварительная проверка на нормальность

С помощью вычисленных числовых характеристик можно определить, является ли выборочное распределение близким к нормальному. Если выборочное распределение близко к **нормальному** (или является таковым), то:

1. в интервалы  $\bar{x} \pm s$ ,  $\bar{x} \pm 2s$  и  $\bar{x} \pm 3s$  должны попадать соответственно приблизительно 68%, 95% и 100% выборочных значений;



2. в не слишком маленькой выборке величина коэффициента вариации  $V$  должна быть не более 33% , т.е.  $V < 0,33$ (см., например, [4]);

3. Оценка эксцесса  $\hat{E}_x$  и коэффициента асимметрии  $\hat{S}_k$  должны быть близки к нулю;

4.  $\bar{x} \approx \hat{M}_e$ .

**Пример 4.** В результате измерения температуры раздела фракции бензин-авиакеросин на установке первичной переработки нефти были получены значения температур, приведенные в таблице 1 (в градусах Цельсия).

*Таблица 1*

| N  | Значение | N  | Значение | N  | Значение | N  | Значение |
|----|----------|----|----------|----|----------|----|----------|
| 1  | 133,5    | 14 | 141,5    | 27 | 144,0    | 40 | 137,5    |
| 2  | 142,0    | 15 | 139,0    | 28 | 142,5    | 41 | 141,5    |
| 3  | 145,5    | 16 | 140,5    | 29 | 139,0    | 42 | 141,0    |
| 4  | 144,5    | 17 | 139,0    | 30 | 137,0    | 43 | 142,5    |
| 5  | 134,5    | 18 | 143,5    | 31 | 136,0    | 44 | 143,5    |
| 6  | 138,5    | 19 | 139,5    | 32 | 137,0    | 45 | 141,0    |
| 7  | 144,0    | 20 | 140,5    | 33 | 138,5    | 46 | 147,0    |
| 8  | 141,0    | 21 | 140,0    | 34 | 139,0    | 47 | 139,5    |
| 9  | 141,5    | 22 | 138,5    | 35 | 139,5    | 48 | 136,5    |
| 10 | 139,5    | 23 | 135,0    | 36 | 140,5    | 49 | 142,0    |
| 11 | 140,0    | 24 | 139,5    | 37 | 139,5    | 50 | 140,0    |
| 12 | 145,0    | 25 | 139,0    | 38 | 140,0    |    |          |
| 13 | 141,5    | 26 | 138,0    | 39 | 140,5    |    |          |

По этой выборке вычислены основные числовые характеристики для объема выборки  $n = 50$ :

$$\begin{aligned}\bar{x} &= 140,2; & \hat{S}_k &= 0,0083; \\ S^2 &= 7,755; & \hat{E}_x &= 0,19; \\ S &= 2,78; & \hat{M}_e &= 140,0. \\ V &= \frac{S}{\bar{x}} = 0,02\end{aligned}$$

Проведена предварительная проверка на нормальность распределения:

1. в интервалы  $\bar{x} \pm s$ ,  $\bar{x} \pm 2s$ ,  $\bar{x} \pm 3s$ , которые в этом случае равны соответственно:

$$140,2 \pm 2,78, (137,40 \div 142,98);$$

$$140,2 \pm 5,56, (134,64 \div 145,76);$$

$$140,2 \pm 8,34, (131,86 \div 148,54),$$

попало, соответственно, 70%, 94% и 100 % выборки;

2. величина  $V = \frac{S}{\bar{x}} = 0,02 < 0,33$ ;

3.  $\hat{E}_x = 0,19$  и  $\hat{S}_k = 0,0083$  можно считать близкими к нулю;

4.  $\bar{x} = 140,2 \approx \hat{M}_e = 140,0$ .

Предварительный анализ показывает, что распределение температуры раздела фракции бензин-авиакеросин не противоречит предположению о нормальности.

## §2. ГРАФИЧЕСКОЕ ПРЕДСТАВЛЕНИЕ ВЫБОРОЧНОГО (ЭМПИРИЧЕСКОГО) РАСПРЕДЕЛЕНИЯ

Наиболее распространенными способами графического представления эмпирических данных (выборки) являются *гистограмма*, *полигон частот* и *эмпирическая функция распределения* (накопленные относительные частоты).

Пусть  $x_{\min}$  и  $x_{\max}$  – соответственно наименьшее и наибольшее значения вариант выборки. Величина  $R = x_{\max} - x_{\min}$  называется *размахом* выборки. Размах делится на число интервалов  $K$  (интервальная группировка), которое можно вычислить по одной из следующих формул:

$$\begin{aligned} K &\approx \sqrt{n}, \\ K &< 5 \cdot \lg n, \\ K &\approx 1 + 3,322 \cdot \lg n \end{aligned}$$

округлив до целого числа.

Обычно предполагают, что количество интервалов должно удовлетворять условию  $5 \leq K \leq 20$ .

Ширина каждого интервала  $d$  вычисляется по формуле  $d = \frac{R}{K}$ . После разбиения на интервалы определяют:

- абсолютные частоты  $m_i$ ,  $i = 1, \dots, K$ , где  $m_i$  – количество элементов выборки, попавших в  $i$  – й интервал (элемент, попавший на границу интервала, относят к какому-нибудь выбранному интервалу, например, левому, или правому; если на границу интервала попадает много элементов выборки, то их делят пополам между левым и правым интервалами);
- относительные частоты  $h_i = \frac{m_i}{n}$ ;

- относительные накопленные частоты  $\sum_{j=1}^i \frac{m_j}{n} = \sum_{j=1}^i h_j, i = 1, \dots, K;$
- середины интервалов  $u_i$ .

Все полученные результаты сводятся в таблицу.

| Номер интервала | Границы интервалов | $m_i$ | $h_i$ | $\sum_{j=1}^i h_j$ | $u_i$ |
|-----------------|--------------------|-------|-------|--------------------|-------|
| 1               |                    | $m_1$ | $h_1$ | $h_1$              | $z_1$ |
| 2               |                    | $m_2$ | $h_2$ | $h_1 + h_2$        | $z_2$ |
| ...             |                    | ...   | ...   | ...                | ...   |

При этом  $\sum_{i=1}^K m_i = n, \sum_{i=1}^K h_i = 1$ .

## 2.1. Гистограмма и полигон частот

**Гистограмма** строится следующим образом. На оси абсцисс откладываются интервалы, и на каждом из них строится прямоугольник, площадь которого равна относительной частоте, соответствующей этому интервалу, т.е. высота прямоугольника (ордината) равна  $\frac{h_i}{d} = \frac{m_i}{nd}$ , так что полная площадь гистограммы равна 1. (Гистограмма является эмпирическим аналогом плотности распределения). Так как множители  $\frac{1}{nd}$  (или  $\frac{1}{d}$ ) можно рассматривать как масштабные, то по оси ординат можно откладывать частоты  $m_i$  или  $h_i$  (правда, в этом случае площадь всех прямоугольников будет равна  $nd$  или  $d$ ).

**Полигон частот** - ломаная линия, которая получается, если из середины каждого интервала  $u_i$  восстановить перпендикуляр высотой  $h_i$  (или  $m_i$ ) и соединить вершины этих перпендикуляров. Полигон частот чаще используют при дискретной группировке.

## 2.2. Эмпирическая функция распределения

Эмпирическую функцию распределения  $F_n(x)$  получают построением ступенчатой кривой относительных накопленных частот;  $F_n(x)$  имеет скачки в точках, соответствующих серединам интервалов  $u_i$ .

По гистограмме и полигону частот судят о виде плотности распределения исследуемой непрерывной случайной величины или о распределении вероятностей дискретной случайной величины. Эмпирическая функция распределения дает представление о функции распределения и используется в основном в статистической проверке гипотез. Кроме того, эмпирическая функция распределения используется для определения эмпирических (выборочных) квантилей. **Квантилем** порядка  $p$  ( $0 < p < 1$ ) называется величина  $x_p$ , определяемая из соотношения  $P\{\xi < x_p\} = F(x_p) = p$ .

**Выборочный квантиль**  $x_p$  определяется из соотношения  $F_n(x_p) = p$ . Задавая  $p$ , можно по графику эмпирической функции распределения оценить, например, значение  $x_p$ , которое исследуемая величина не превзойдет с вероятностью  $p$ , либо, задавая  $x_p$ , по тому же графику оценить соответствующую вероятность  $p$ . По  $F_n(x)$  можно оценить медиану из соотношения  $F_n(\hat{M}_e) = 0,5$ .

**Пример 1.** Построение гистограммы, полигона частот и эмпирической функции распределения по данным примера 4 из §1.

$$x_{\min} = 133,5,$$

$$x_{\max} = 147,0,$$


$$R = 13,5,$$


$$n = 50.$$

Количество интервалов:  $K \approx \sqrt{n}$ ,  $K = 7$ .

Ширина интервала:  $d = \frac{R}{K} = 1,93$ .

| Номер интервала | Границы         | $m_i$ | $h_i = m_i/n$ | $\sum_{j=1}^i h_j$ | $u_i$  |
|-----------------|-----------------|-------|---------------|--------------------|--------|
| 1               | 133,50 – 135,43 | 3     | 0,06          | 0,06               | 134,47 |
| 2               | 135,43 – 137,36 | 4     | 0,08          | 0,14               | 136,40 |
| 3               | 137,36 – 139,29 | 10    | 0,20          | 0,34               | 138,33 |
| 4               | 139,29 – 141,22 | 17    | 0,34          | 0,68               | 140,26 |
| 5               | 141,22 – 143,15 | 8     | 0,16          | 0,84               | 142,19 |
| 6               | 143,15 – 145,08 | 6     | 0,12          | 0,96               | 144,12 |
| 7               | 145,08 – 147,00 | 2     | 0,04          | 1                  | 146,05 |





Эмпирическая функция распределения

По эмпирической функции распределения можно оценить, например, вероятность того, что температура раздела фракции бензин-авиакеросин будет ниже  $143^{\circ}\text{C}$  :

$$P\{T < 143\} \approx 0,84.$$